Evaluación de RF-DETR para la Detección Multiespecie en Escenarios de Alta Oclusión en la Sabana Africana

1st Amir Sadour
MaIA
Universidad de los Andes
Bogotá, Colombia
a.sadour@uniandes.edu.co

2nd Camilo Rodriguez
MaIA
Universidad de los Andes
Bogotá, Colombia
ca.rodriguezs123@uniandes.edu.co

3rd Claudia Agudelo
MaIA
Universidad de los Andes
Cali, Colombia
cj.agudelo@uniandes.edu.co

4th Luis Manrique
MaIA
Universidad de los Andes
Bogotá, Colombia
l.manriquec@uniandes.edu.co

***Resumen*—Este artículo aborda el desafío crítico del monitoreo automatizado de fauna silvestre en imágenes aéreas, específicamente en escenarios de alta densidad (manadas). El problema central radica en que los detectores tradicionales basados en CNN fallan ante la oclusión y superposición de animales; el algoritmo de Supresión de No Máximos (NMS) tiende a eliminar detecciones válidas, provocando un subconteo sistemático, mientras que modelos como HerdNet, aunque evitan el NMS, luchan con la clasificación de especies minoritarias.**

Como solución, se propone la implementación de RF-DETR. Esta arquitectura utiliza mecanismos de atención para modelar dependencias globales y realiza una predicción de conjuntos end-to-end, lo que permite eliminar por completo la necesidad de NMS y gestionar mejor las oclusiones severas.

La metodología consistió en comparar tres variantes de RF-DETR (Nano, Small, Large) frente al modelo base HerdNet, utilizando un dataset de mamíferos africanos. Se aplicó una estrategia de entrenamiento en dos fases, donde la segunda etapa incorporó Minería de Negativos Difíciles (HNM) para refinar la precisión y reducir falsos positivos en fondos complejos.

Los principales resultados determinaron que RF-DETR Small es la variante óptima. Este modelo alcanzó un F1-Score del 90.24 %, superando significativamente al baseline (83.26 %) y reduciendo el error medio de conteo (MAE) en un 39.47 %. Además, demostró ser un 56 % más rápido en inferencia que HerdNet y mejoró sustancialmente la detección de especies minoritarias (como el cobo de agua), validando la superioridad de los Transformers para equilibrar precisión y eficiencia en tareas de conservación.

***Palabras clave*—RF-DETR, HerdNet, DINOv2,HNM, detección de animales, imágenes aéreas, manadas densas**

I. Introducción

El monitoreo automatizado de la fauna silvestre mediante imágenes aéreas es crucial para la conservación ecológica, pero enfrenta un desafío crítico en la sabana africana: la detección precisa en escenarios de alta densidad. Especies gregarias como elefantes y búfalos forman manadas compactas con severa oclusión y superposición entre individuos, condiciones donde los sistemas de visión por computador convencionales fallan sistemáticamente.

El problema fundamental radica en las arquitecturas tradicionales basadas en CNN y anclas, que dependen del algoritmo de Supresión de No Máximos (NMS). En manadas densas, el NMS elimina erróneamente detecciones válidas de animales contiguos, provocando un subconteo crónico. Aunque alternativas como HerdNet [2] evitan el NMS mediante la estimación de densidad por puntos, su dependencia de backbones CNN limita la captura del contexto global necesario para una clasificación robusta, afectando especialmente a las especies minoritarias.

Este trabajo se justifica por la necesidad de una solución que supere simultáneamente las limitaciones de oclusión y discriminación semántica. El objetivo principal es implementar y evaluar la arquitectura **RF-DETR** (*Real-Time Detection Transformer*) [5] en este contexto desafiante. Nuestra hipótesis es que el mecanismo de atención de los Transformers, capaz de modelar dependencias globales, junto con la predicción de conjuntos *end-to-end* que elimina por completo la necesidad del NMS, ofrece una solución estructural al problema del subconteo en manadas.

Las principales contribuciones de este estudio son: (1) Una comparación de tres variantes de RF-DETR (Nano, Small, Large) frente al baseline HerdNet. (2) Un análisis del compromiso entre precisión en alta densidad y costo computacional de las arquitecturas, identificando configuraciones óptimas para el despliegue práctico. (3) La validación de una estrategia de entrenamiento de dos fases con Minería de Negativos Difíciles (HNM) para refinar la precisión en fondos complejos.

II. Estado del arte

La monitorización de la fauna silvestre mediante imágenes aéreas ha evolucionado significativamente, pasando de métodos de conteo manual propensos a sesgos humanos a sistemas automatizados basados en visión por computador. La revisión de la literatura revela una transición tecnológica desde las Redes Neuronales Convolucionales (CNN) tradicionales hacia arquitecturas especializadas en densidad y, más recientemente, hacia modelos basados en Transformers y mecanismos de atención. A continuación, se describen los enfoques más relevantes y la evolución técnica que fundamenta este proyecto.

II-A. Detección basada en CNNs y limitaciones en manadas densas

Históricamente, la detección de animales en imágenes aéreas se ha abordado mediante detectores de objetos de propósito general basados en anclas (*anchor-based*), como Faster R-CNN, Libra R-CNN y RetinaNet. Estudios previos sobre el mismo conjunto de datos utilizado en esta investigación demostraron que modelos como Libra R-CNN podían alcanzar una precisión media (mAP) del 80 % en condiciones ideales [10].

Sin embargo, como sintetizan diversas revisiones del campo [1], estas arquitecturas presentan dos limitaciones fundamentales en el contexto de manadas densas:

1. Dependencia del NMS: el algoritmo de Supresión de No Máximos tiende a eliminar detecciones válidas cuando varios animales aparecen muy próximos, lo que provoca subconteo sistemático.

2. Objetos pequeños y ocluidos: en imágenes aéreas, los animales suelen ocupar pocos píxeles, y las CNN tradicionales tienen dificultades para distinguir individuos contiguos en fondos heterogéneos.

En estudios aplicados a fauna africana, Delplanque et al. observaron caídas críticas de precisión en grupos densos debido exactamente a estos factores [10]. Estas limitaciones motivaron el desarrollo de modelos específicamente diseñados para entornos con oclusión extrema.

II-B. HerdNet y el enfoque basado en puntos

Para resolver el dilema entre la localización precisa y el conteo en masas, Delplanque et al. propusieron **HerdNet**, el cual se establece como el modelo de referencia (*baseline*) para este proyecto [2]. HerdNet abandona el enfoque de cajas delimitadoras en favor de una estimación basada en puntos, inspirada en técnicas de conteo de multitudes (*crowd counting*).

Esta arquitectura utiliza un mapa de Transformada de Distancia Inversa Focal (FIDT).Este mapa genera picos localizados en el centro de cada animal, permitiendo detectar individuos incluso cuando no hay contornos claros, evitar por completo el uso de NMS, y mantener robustez en presencia de oclusiones y variaciones de escala.

Aunque HerdNet superó a las arquitecturas basadas en anclas (como Faster R-CNN) y basadas en densidad pura (como DLA-34) con un F1-Score del 73.6 % y un RMSE de 9.8, sobre el conjunto de datos de múltiples especies utilizado en este proyecto, presenta desafíos en la clasificación de especies minoritarias y una dependencia de arquitecturas de CNN convencionales que pueden no capturar eficazmente el contexto global de la imagen.

II-C. La revolución de los Transformers: WildlifeMapper, OpenWildlife y RF-DETR

La incorporación de arquitecturas tipo *Transformer* ha marcado un punto de inflexión en la detección de objetos en imágenes aéreas. A diferencia de las CNN convencionales, estos modelos introducen mecanismos de atención capaces de capturar relaciones espaciales de largo alcance, lo que resulta crítico para manejar variaciones extremas de escala y fondos heterogéneos.

WildlifeMapper y OpenWildlife: Kumar et al. presentaron **WildlifeMapper** [3], una arquitectura que integra módulos de refinamiento local para capturar estructuras de alta frecuencia. Este enfoque ha demostrado ser superior en el manejo de imágenes aéreas de muy alta resolución (hasta 8400×5500 px), permitiendo una localización precisa en paisajes vastos.

Por otro lado, Patel et al. propusieron **OpenWildlife** [4], un detector de vocabulario abierto basado en la arquitectura *Grounding-DINO*. Este modelo combina un *backbone* visual (Swin Transformer) con un codificador de lenguaje (BERT), permitiendo la detección de fauna guiada por descripciones textuales naturales. Si bien ofrece una gran capacidad de generalización hacia especies no vistas durante el entrenamiento, su arquitectura pesada conlleva un costo computacional que limita su escalabilidad en análisis masivos.

RF-DETR: Eficiencia en Tiempo Real: Más recientemente, Robinson et al. introdujeron **RF-DETR** [5], un *Detection Transformer* diseñado específicamente para optimizar el equilibrio entre precisión y latencia. Esta arquitectura se distingue por dos innovaciones clave:

- **Búsqueda de Arquitectura Neuronal (NAS) de peso compartido:** Permite ajustar dinámicamente la profundidad del decodificador, el número de *queries* y las ventanas de atención sin necesidad de reentrenar el modelo desde cero.
- **Backbone DINOv2 [6]:** Incorpora representaciones visuales robustas obtenidas mediante un preentrenamiento autosupervisado a escala de internet.

En benchmarks estándar como COCO y el complejo RF100-VL, RF-DETR ha superado a detectores modernos como YOLOv8 y D-FINE, logrando métricas superiores a 60 AP con latencias por debajo de los 40 ms [5]. Crucialmente para este proyecto, RF-DETR opera como un detector *end-to-end*, eliminando la necesidad de algoritmos de post-procesamiento manuales como la Supresión de No Máximos (NMS). Esta característica lo hace teóricamente superior en escenarios de alta densidad, donde el NMS tradicional tiende a suprimir individuos contiguos.

II-D. Análisis, brechas identificadas y propuesta

La revisión exhaustiva de la literatura permite identificar tres brechas tecnológicas principales que limitan el monitoreo automatizado de fauna en la actualidad:

1. **Precisión limitada en densidad extrema:** Los modelos tradicionales basados en anclas (como la familia YOLO o Faster R-CNN) fallan sistemáticamente en la detección de manadas densas. Esto se debe intrínsecamente al uso de NMS, que al intentar eliminar duplicados, elimina erróneamente detecciones válidas de animales que se superponen o están muy próximos entre sí [1].
2. **Dilema entre localización y contexto semántico:** Enfoques como HerdNet [2] resolvieron eficazmente el problema de la oclusión mediante la estimación de

densidad basada en puntos. Sin embargo, al depender de CNNs tradicionales, su capacidad para capturar el contexto global de la imagen es limitada, lo que afecta su capacidad de generalización y clasificación fina en entornos complejos.

3. **Costo computacional de los modelos fundacionales:** Aunque métodos recientes como WildlifeMapper y OpenWildlife ofrecen un desempeño excelente y capacidades de vocabulario abierto, sus requerimientos computacionales son prohibitivos para el despliegue en escenarios de conservación con recursos limitados o para el procesamiento de grandes volúmenes de datos de drones [4].

Síntesis y propuesta de valor: El análisis de estas limitaciones sugiere que existe una oportunidad no explorada en la intersección de estas tecnologías. Se plantea que la implementación de **RF-DETR** en el contexto de manadas densas podría cerrar estas brechas simultáneamente.

La hipótesis central es que la capacidad de los Transformers para modelar relaciones globales y prescindir del NMS permitirá mejorar la recuperación (*recall*) de individuos en manadas densas, superando el conteo de HerdNet. Simultáneamente, se espera que el uso de un *backbone* robusto como DINOv2 mejore la discriminación entre especies (reduciendo la confusión reportada en HerdNet), todo ello manteniendo una eficiencia computacional viable para su aplicación práctica.

III. Metodología

La metodología adoptada sigue el ciclo de vida estándar de un proyecto de aprendizaje automático, estructurándose en cuatro fases principales: preparación de datos, modelado y experimentación, estrategia de entrenamiento y despliegue. El enfoque se centró en superar las limitaciones de los detectores tradicionales en escenarios de alta densidad mediante la implementación de arquitecturas basadas en Transformers con optimización de arquitectura neuronal (NAS).

III-A. Gestión y Procesamiento de Datos

III-A1. Descripción del Dataset: Se utilizó el conjunto de datos consolidado por Delplanque et al. [10], el cual agrega 10.239 anotaciones de mamíferos africanos provenientes de dos fuentes principales: el Parque Nacional Virunga (RDC) y el *Aerial Elephant Dataset* (AED). El dataset incluye seis clases de especies objetivo: Búfalo, Elefante, Kob, Topi, Facóquero y Cobo de agua.

Las imágenes se caracterizan por una vista cenital con una resolución espacial muy alta, presentando un *Ground Sampling Distance* (GSD) que varía entre 2.4 cm y 13 cm por píxel. El conjunto de datos presenta un desafío significativo de desbalance de clases, donde especies mayoritarias como el elefante superan en proporción 12:1 a especies minoritarias como el cobo de agua. La distribución detallada de individuos por especie y su división en los conjuntos de entrenamiento, validación y prueba se presenta en la tabla I.

Tabla I
Distribución de individuos por especie en los conjuntos de entrenamiento, validación y prueba.

Especie	Entrenamiento	Validación	Prueba	Total
Búfalo	1058 (70 %)	102 (7 %)	349 (23 %)	1509
Elefante	2012 (68 %)	264 (9 %)	688 (23 %)	2964
Kob	1732 (73 %)	161 (7 %)	477 (20 %)	2370
Topi	1678 (62 %)	369 (13 %)	675 (25 %)	2722
Facóquero	316 (73 %)	43 (10 %)	74 (17 %)	433
Cobo de agua	166 (69 %)	39 (16 %)	36 (15 %)	241
Total	**6962 (68 %)**	**978 (10 %)**	**2299 (22 %)**	**10 239**

III-A2. Preprocesamiento y Aumento de Datos: Dada la alta resolución de las imágenes aéreas originales, se implementó una estrategia de *tiling* (teselado) adaptativa. Para alinearse con las arquitecturas de los modelos seleccionados, se generaron recortes (*patches*) en tres resoluciones específicas: 384×384, 512×512 y 560×560 píxeles. Se mantuvo un solapamiento (*overlap*) estratégico entre teselas para evitar el corte de animales en los bordes de la imagen.

Para mejorar la robustez del modelo, se aplicó un pipeline de aumento de datos (*data augmentation*) que incluyó:

- **Transformaciones geométricas:** Rotaciones aleatorias, volteo horizontal/vertical y recortes aleatorios.
- **Transformaciones fotométricas:** Ajustes de brillo, contraste y saturación para simular la variabilidad lumínica.

III-B. Arquitecturas de Modelado

III-B1. Modelo de Referencia (Baseline): HerdNet: Para establecer una línea base rigurosa, se replicó la arquitectura **HerdNet** utilizando los scripts y clases definidos en su repositorio oficial [2]. Este modelo es una adaptación de la arquitectura *CenterNet* diseñada específicamente para el conteo de multitudes, que abandona las cajas delimitadoras (bounding boxes) en favor de una estimación basada en puntos.

Como se ilustra en la Figura 2, la arquitectura consta de un codificador-decodificador basado en **DLA-34** (Deep Layer Aggregation), el cual bifurca el procesamiento en dos ramas especializadas:

1. **Rama de Localización (Localization Map):** Genera un mapa de densidad de alta resolución (256×256 píxeles para una entrada de 512×512) utilizando la Transformada de Distancia Inversa Focal (FIDT). Este mapa predice picos de densidad en el centro de cada animal, permitiendo separar individuos en aglomeraciones densas donde las cajas delimitadoras se solaparían significativamente.
2. **Rama de Clasificación (Classification Maps):** Produce mapas de menor resolución (16×16 píxeles) que contienen la información semántica de la especie. Durante la inferencia, el modelo utiliza una Estrategia de Detección de Máximos Locales (LMDS) para extraer las coordenadas precisas del mapa de localización y asignarles la clase correspondiente del mapa de clasificación.

III-B2. Modelo Propuesto: RF-DETR: La solución propuesta se basa en **RF-DETR**, una arquitectura diseñada para

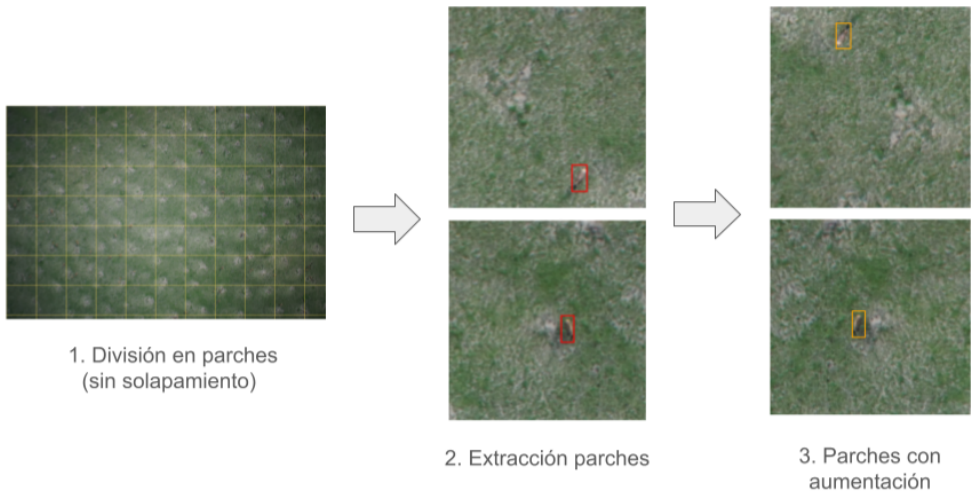


Figura 1. Visualización del preprocesamiento: extracción de recortes (tiling) y ejemplos de aumentación de datos aplicados para el entrenamiento de HerdNet y RF-DETR.

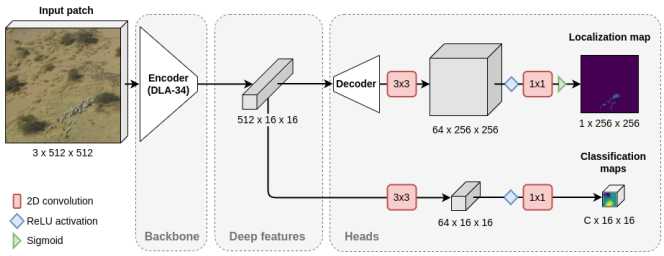


Figura 2. Arquitectura de HerdNet. El modelo utiliza un backbone DLA-34 y se divide en dos cabezales: uno para generar un mapa de localización de alta resolución (arriba) y otro para mapas de clasificación de baja resolución (abajo) [2].

optimizar el equilibrio entre precisión y latencia en aplicaciones de tiempo real. Como se ilustra en la Figura 3, su diseño integra componentes avanzados para mejorar la generalización y el manejo de oclusiones:

- **Backbone DINOv2:** Utiliza un *Vision Transformer* (ViT-L/14) pre-entrenado con aprendizaje autosupervisado. Este backbone provee representaciones visuales robustas que facilitan la adaptación a dominios específicos con pocos datos anotados.
- **Extracción de Características Uniescala:** A diferencia de otros Transformers que procesan múltiples escalas, RF-DETR emplea una estrategia de extracción de características de una sola escala (ej. 640×1280 px) para reducir la sobrecarga computacional sin sacrificar significativamente la precisión.
- **Cabezal Transformer y Atención Deformable:** Incorpora un mecanismo de atención cruzada deformable (*Deformable Cross-Attention*) en el decodificador. Esto permite al modelo enfocarse selectivamente en características espacialmente relevantes, mejorando la detección en condiciones de oclusión severa, desorden visual (*clutter*) y camuflaje, típicas de las manadas densas en la sabana.
- **Predicción de Conjuntos sin NMS:** El modelo realiza una predicción directa de conjuntos de cajas delimitadoras, eliminando la necesidad de anclajes (*anchor boxes*) y de la Supresión de No Máximos (NMS). Esto es crítico para resolver el problema de subconteo en manadas densas, donde el NMS tradicional suprimiría detecciones válidas muy próximas.
- **Variantes:** Para evaluar el compromiso entre precisión y costo, se implementaron tres variantes: Nano (384 px), Small (512 px) y Large (560 px), permitiendo adaptar la complejidad del modelo a los recursos disponibles.

III-C. Estrategia de Entrenamiento

Se diseñó un protocolo dividido en dos etapas principales: la replicación del *baseline* y el entrenamiento especializado del modelo propuesto, adaptando la técnica de minería de negativos difíciles (*Hard Negative Mining*) para maximizar la precisión.

III-C1. Replicación de HerdNet: El proceso se realizó en dos fases secuenciales:

1. **Fase 1 (Entrenamiento Inicial):** Se entrenó el modelo durante 100 épocas con un *learning rate* inicial de 1×10^{-4} y un optimizador AdamW. La función de pérdida combinó *Focal Loss* para la localización y *Cross Entropy Loss* ponderada para la clasificación, asignando pesos específicos ($w = [0{,}1; 1{,}0; 2{,}0; \dots]$) para mitigar el desbalance de clases.
2. **Fase 2 (Refinamiento con HNP):** Se realizó un segundo entrenamiento de 50 épocas con una tasa de aprendizaje reducida a 1×10^{-6}. En esta etapa se introdujeron los parches negativos difíciles (*Hard Negative Patches* - HNP), generados al ejecutar el modelo de la Fase 1 sobre las imágenes de entrenamiento y recolectar las predicciones de falsos positivos con alta confianza.

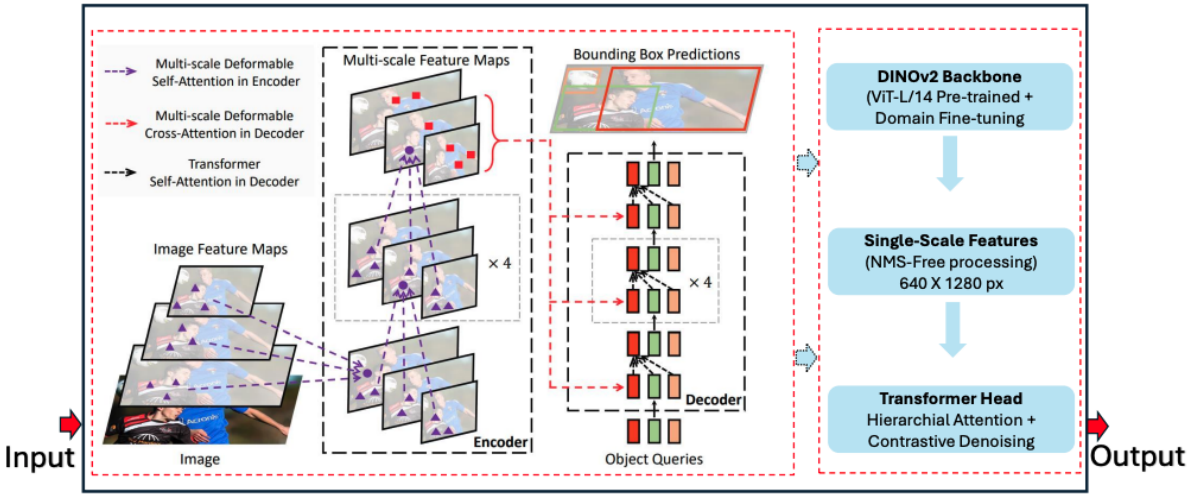


Figura 3. Arquitectura de RF-DETR para la detección de objetos. Muestra el flujo desde el backbone DINOv2, pasando por la extracción de características uniescala, hasta el cabezal Transformer con atención jerárquica y eliminación de ruido contrastivo. [5]

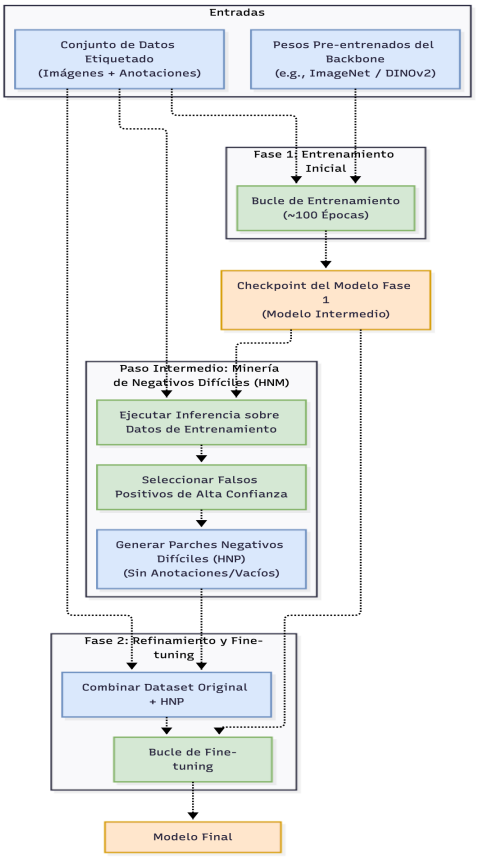


Figura 4. Flujo de entrenamiento.

III-C2. Adaptación para RF-DETR: Se replicó la estrategia de dos fases de HerdNet con las siguientes adaptaciones para la arquitectura Transformer:

III-C2a. Hiperparámetros de Entrenamiento: **Fase 1:** Se utilizó el *backbone* DINOv2 pre-entrenado con normalización ImageNet y learning rate por defecto del framework (con decaimiento por capas). Se implementó un callback personalizado para monitorear métricas de HerdNet durante el entrenamiento.

Fase 2: Fine-tuning con learning rate reducido (1×10^{-5} para las tres variantes), aumentación multi-escala activada, y regularización mediante weight decay y EMA. El dataset ampliado con HNP mantuvo las anotaciones originales solo en los parches positivos, forzando al modelo a predecir ausencia de objetos en regiones visualmente confusas.

III-C2b. Inferencia y Evaluación: Se empleó un `SimpleStitcher` para procesar imágenes completas en ventanas deslizantes y reconstruir detecciones en coordenadas originales. Las métricas se calcularon con el framework de HerdNet (radio de 20 píxeles) para mantener comparabilidad directa.

III-D. Herramientas y Despliegue

El desarrollo de la solución siguió una arquitectura de microservicios modular, separando el motor de inferencia de la capa de presentación y orquestando el despliegue mediante prácticas de Infraestructura como Código (IaC).

III-D1. Backend y Optimización de Inferencia: El núcleo del sistema se implementó utilizando **FastAPI**, exponiendo una API REST de alto rendimiento. Para optimizar la latencia en un entorno de producción, se migró el modelo entrenado en PyTorch al formato **ONNX Runtime**. Esta decisión técnica permitió:

- Maximizar la velocidad de inferencia, reduciendo la dependencia de GPUs costosas en inferencia.
- Disminuir la huella de memoria y garantizar la portabilidad entre diferentes arquitecturas de hardware.

La API gestiona endpoints críticos como `/api/inference` para el procesamiento de imágenes y `/health` para el monitoreo de disponibilidad.

III-D2. Interfaz de Usuario (Frontend): Para la validación visual y comparación de experimentos, se desarrolló una *Single Page Application* (SPA) basada en el stack moderno de **React** y **TypeScript**, construida con Vite. La interfaz integra:

- **Visualización de Detecciones:** Componentes de Canvas personalizados para renderizar las cajas delimitadoras (*bounding boxes*) sobre las imágenes aéreas de alta resolución.
- **Comparativa de Modelos:** Módulos específicos (*ExperimentComparison*) que permiten contrastar visualmente el rendimiento entre diferentes versiones del modelo (e.g., RF-DETR vs. Baseline).

III-D3. Infraestructura Cloud y Orquestación: El despliegue en producción se realizó sobre **Amazon Web Services (AWS)**, utilizando **Terraform** para garantizar la reproducibilidad de la infraestructura. La arquitectura, diseñada para alta disponibilidad y eficiencia de costos, se compone de:

1. **Cómputo Serverless (AWS ECS & Fargate):** La aplicación se contenedorizó con Docker y se desplegó en Amazon ECS utilizando la estrategia de capacidad *Fargate Spot*, logrando una reducción de costos operativa estimada del 70 %.
2. **Gestión de Tráfico:** Se implementó un *Application Load Balancer* (ALB) distribuido en múltiples zonas de disponibilidad, con verificaciones de estado automáticas para gestionar el tráfico de inferencia.
3. **Seguridad y Monitoreo:** La red se aisló mediante una VPC privada, restringiendo el acceso a los contenedores únicamente a través del ALB. El monitoreo de logs y métricas de rendimiento se centralizó en *CloudWatch*, asegurando la observabilidad del sistema en tiempo real.

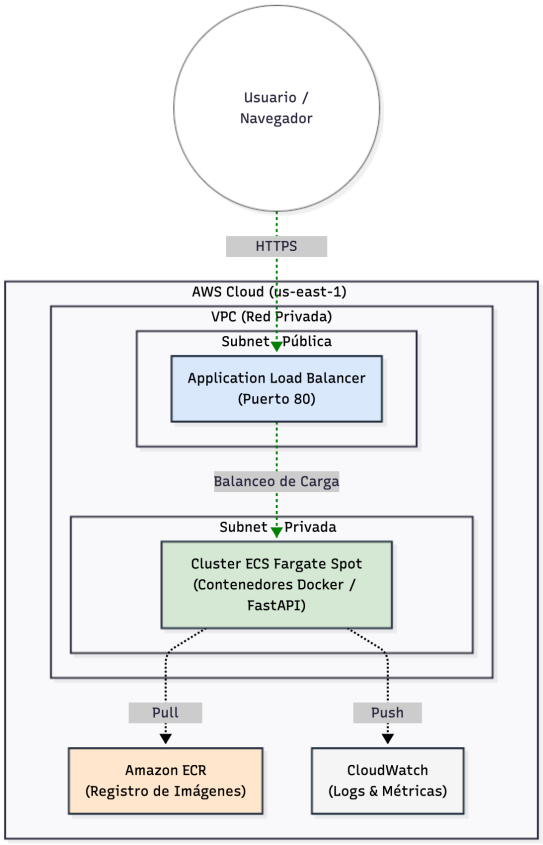


Figura 5. Arquitectura de despliegue de la solución en la nube.

IV. Resultados y evaluación

Se presenta una evaluación del rendimiento de tres variantes de RF-DETR (Nano, Small, Large) en comparación con HerdNet, el modelo de referencia establecido en la literatura para la detección de fauna en manadas densas. Los resultados se organizan en subsecciones que analizan: (1) el rendimiento cuantitativo general, (2) la precisión por especie y el impacto en clases minoritarias, (3) el efecto del HNM, y (4) la eficiencia computacional y viabilidad práctica de los modelos.

IV-A. Rendimiento Cuantitativo Comparativo

IV-A1. Métricas: Para evaluar los modelos tomamos las métricas de referencia de *HerdNet*: precisión, recall y f1, en sus variantes por clase y binaria, en esta última una confusión entre especies de animales no se penaliza, ya que solo se tiene en cuenta la detección de un animal, independiente de su especie. De esta forma definimos las métricas como sigue:

- **Verdadero positivo (VP)**: una detección es un verdadero positivo si su centro está cerca de un animal de la fuente de la verdad por no más de **20px** y la clase está correctamente clasificada (métricas por clase).
- **Falso negativo (FN)**: se considera un falso negativo si para una anotación de la fuente de la verdad no existe una detección en predicciones que esté a menos de **20px**. Para métricas por clase, la clase debe ser igual en la fuente de la verdad y detecciones.
- **Falso positivo (FP)**: se considera un falso positivo toda detección que no esté cerca de ninguna etiqueta de la fuente de la verdad (menos de **20px** de distancia desde el centro) cuya clase coincida (para el caso de métricas por clase).

Las métricas se definen como:

$$\text{Precisión (P)} = \frac{VP}{VP + FP}$$

$$\text{Recall (R)} = \frac{VP}{VP + FN}$$

$$\text{Puntaje F1} = 2 \cdot \frac{\text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}}$$

$$\text{MAE} = \frac{1}{I} \sum_{i=1}^{I} |\hat{n}_i - n_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{I} \sum_{i=1}^{I} (\hat{n}_i - n_i)^2}$$

IV-A2. Métricas globales de rendimiento en el conjunto de prueba: La Tabla II presenta las métricas globales de rendimiento para los cuatro modelos evaluados en sus dos fases de entrenamiento. Esta comparación permite analizar tanto el rendimiento final como el impacto del HNM en cada arquitectura. Los resultados de Fase 2 demuestran mejoras consistentes de las variantes RF-DETR sobre el baseline HerdNet en las métricas críticas de precisión y conteo.

Tabla II
MÉTRICAS GLOBALES DE RENDIMIENTO EN EL CONJUNTO DE PRUEBA: COMPARACIÓN FASE 1 (ENTRENAMIENTO INICIAL) VS FASE 2 (CON HARD NEGATIVE MINING).

Modelo	Fase	Precision	Recall	F1-Score	MAE	RMSE
HerdNet	Fase 1	0.6154	0.8673	0.7200	4.3450	9.8746
	Fase 2	0.8229	0.8425	0.8326	1.8953	3.6700
RF-DETR nano	Fase 1	0.5023	0.9378	0.6542	7.7403	10.9341
	Fase 2	0.8161	0.6407	0.7178	3.7287	6.8957
RF-DETR small	Fase 1	0.2615	0.9517	0.4103	23.5310	32.0026
	Fase 2	**0.9385**	0.8691	**0.9024**	**1.1473**	**2.4112**
RF-DETR large	Fase 1	0.6133	0.9230	0.7369	4.8643	7.5742
	Fase 2	0.8893	**0.8839**	0.8866	1.2248	3.0966

RF-DETR small se posiciona como el modelo de mejor desempeño global, alcanzando un F1-Score de 90.24 %, lo que representa una mejora del **8.37 %** sobre HerdNet (83.26 %). Esta mejora se debe principalmente a un incremento sustancial en precisión (93.85 % vs 82.29 %), indicando una reducción significativa de falsos positivos. Simultáneamente, el recall se mantuvo competitivo (86.91 % vs 84.25 %), demostrando que la eliminación del NMS no compromete la capacidad de recuperación de individuos.

El análisis de las métricas de error de conteo revela mejoras aún más pronunciadas. RF-DETR small redujo el MAE en un **39.47 %** (de 1.90 a 1.15) y el RMSE en un **34.29 %** (de 3.67 a 2.41) en comparación con HerdNet Fase 2. Estas reducciones son críticas para aplicaciones de conservación, donde el conteo preciso de poblaciones es fundamental para la toma de decisiones de gestión.

RF-DETR large, con un F1-Score de 88.66 %, también superó significativamente a HerdNet (+6.48 %), alcanzando el mejor recall de 88.39 %. Sin embargo, **RF-DETR nano** presenta un rendimiento considerablemente inferior (F1=71.78 %), especialmente en recall (64.07 %), lo que sugiere que la arquitectura nano carece de la capacidad expresiva necesaria para capturar la complejidad de escenarios multiespecie con alta oclusión.

Un patrón crítico emerge al comparar ambas fases de entrenamiento: todos los modelos en Fase 1 priorizaban recall sobre precisión, resultando en F1-Scores subóptimos debido a la generación excesiva de falsos positivos. RF-DETR small mostró el comportamiento más extremo, alcanzando un recall de 95.17 % en Fase 1 pero con una precisión de apenas 26.15 %, generando un MAE de 23.53. El refinamiento mediante HNM en Fase 2 corrigió este desbalance sistemáticamente, mejorando la precisión de todos los modelos mientras mantenía niveles aceptables de recall. Este patrón valida la necesidad del entrenamiento en dos fases para aplicaciones donde la precisión de conteo es tan crítica como la capacidad de detección.

IV-B. Análisis por Especie y Clases Minoritarias

La Figura 6 presenta el F1-Score desagregado por especie, revelando patrones diferenciados de rendimiento que validan una de las hipótesis centrales de este trabajo: los Transformers mejoran la discriminación en especies minoritarias.

Los resultados más destacados se observan en las dos especies minoritarias del dataset:

Cobo de agua: RF-DETR large alcanzó un F1-Score de **0.816**, representando una mejora del **19.1 %** sobre HerdNet (0.685). Esta mejora se atribuye a un recall excepcional de 86.1 % y una precisión de 77.5 %, indicando que el modelo captura exitosamente la mayoría de los individuos de esta especie extremadamente subrepresentada (241 individuos en total, apenas el 2.4 % del dataset).

Facóquero: Aunque la mejora fue más modesta, RF-DETR large alcanzó un F1-Score de 0.449 versus 0.415 de HerdNet (mejora del 8.2 %). Sin embargo, la precisión mejoró significativamente (0.484 vs 0.388), reduciendo los falsos positivos en un 24.7 %.

Para especies mayoritarias como Elefante y Kob, el rendimiento tuvo mejoras incrementales de RF-DETR. Lo que indica que no se sacrifica el rendimiento en clases bien representadas mientras se mejora sustancialmente la detección de especies minoritarias, un equilibrio crítico para aplicaciones reales de monitoreo multiespecie.

IV-C. Impacto del Hard Negative Mining

Como se observa en la Tabla II, la estrategia de dos fases con HNM fue fundamental para alcanzar el rendimiento final reportado. La comparación entre Fase 1 y Fase 2 revela mejoras diferenciadas según la arquitectura, reflejando distintos niveles de susceptibilidad a la generación de falsos positivos durante el entrenamiento inicial.

RF-DETR small mostró el impacto más significativo del HNM, con un incremento en precisión de 0.26 a 0.94 (mejora relativa del **258.9 %**), lo que indica que el modelo sin refinamiento presentaba una alta tasa de falsos positivos en patrones ambiguos. El F1-Score pasó de 0.41 a 0.90 (mejora del **119.9 %**), transformándolo de un modelo con rendimiento limitado a la mejor solución del estudio. Este comportamiento sugiere que la arquitectura small, con su mayor capacidad expresiva, es particularmente susceptible a generar falsos positivos en fondos complejos cuando se entrena sin ejemplos negativos difíciles.

En contraste, **HerdNet** y **RF-DETR large** mostraron mejoras más moderadas pero consistentes. HerdNet incrementó su precisión en +33.7 % (de 0.62 a 0.82) y su F1-Score en +15.6 % (de 0.72 a 0.83), mientras que RF-DETR large mejoró +45.0 % en precisión (de 0.61 a 0.89) y +20.3 % en F1-Score (de 0.74 a 0.89). Estas mejoras más moderadas indican que ambas arquitecturas poseían cierta robustez intrínseca contra falsos positivos desde la Fase 1, requiriendo un refinamiento menos agresivo. **RF-DETR nano**, por su parte, mejoró su

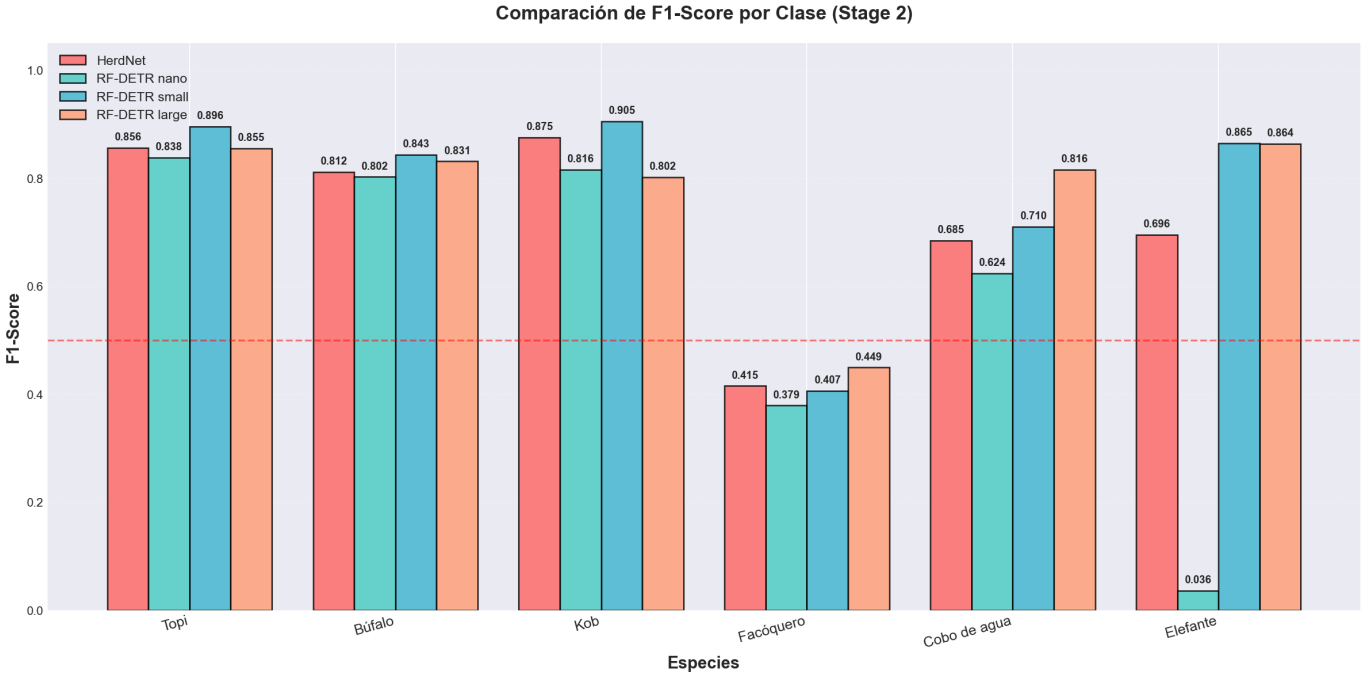


Figura 6. F1-Score por especie para todos los modelos en Fase 2.

precisión en +62.5 % (de 0.50 a 0.82), aunque su F1-Score final (0.72) permaneció por debajo del baseline, confirmando las limitaciones arquitectónicas de la variante más compacta.

La incorporación sistemática de estos ejemplos difíciles en la Fase 2 permitió a los modelos desarrollar representaciones más discriminativas, aprendiendo a distinguir características texturales y contextuales sutiles que separan animales reales de elementos de background visualmente similares.

IV-D. Eficiencia Computacional

La Figura 7 presenta la distribución de latencias de inferencia por imagen medidas en el conjunto de prueba utilizando una GPU NVIDIA A100 (80GB VRAM). Los diagramas de caja revelan tanto la tendencia central como la variabilidad de los tiempos de procesamiento para cada modelo.

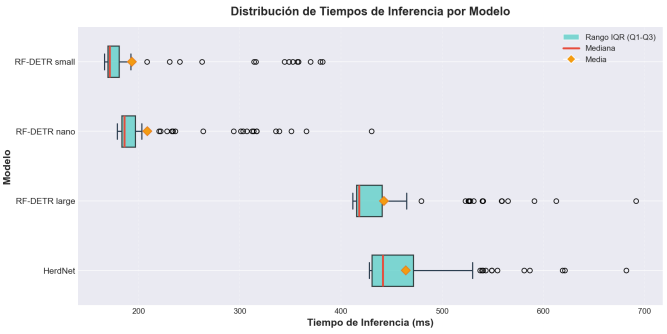


Figura 7. Distribución de tiempos de inferencia por modelo en conjunto de prueba. La línea roja indica la mediana y el rombo naranja la media.

RF-DETR small representa el modelo más eficiente, con una mediana de 171.49 ms y una media de 193.39 ms por imagen, superando incluso a RF-DETR nano (mediana: 186.16 ms, media: 208.53 ms).

HerdNet y RF-DETR large presentan latencias comparables, con medianas de 441.27 ms y 417.88 ms respectivamente, siendo aproximadamente 2.4× más lentos que RF-DETR small. Sin embargo, ambos modelos exhiben mayor variabilidad temporal, como evidencian los outliers presentes en la figura, sugiriendo dependencia en la complejidad de las escenas procesadas.

Para aplicaciones de monitoreo de fauna donde tanto la precisión como el throughput son críticos, RF-DETR small representa la opción óptima al combinar el mejor F1-Score con la menor latencia y mayor consistencia temporal.

IV-E. Análisis de Matrices de Confusión sobre las detecciones

La Figura 8 presenta la matriz sobre las detecciones para RF-DETR small, el modelo de mejor desempeño.

El análisis de la diagonal principal revela una alta eficacia en la clasificación correcta para la mayoría de las especies: Topi (99 %), Búfalo (92 %), Kob (89 %) y Cobo de agua (88 %), destacando un desempeño perfecto (100 %) en las clases Facóquero y Elefante.

Los patrones de confusión interespecífica más relevantes son:

- **Kob → Topi (10 %):** Representa la confusión más significativa del modelo. Es un error unidireccional (la inversa es despreciable), atribuible a la similitud morfológica entre estos antílopes de tamaño medio y pelaje rojizo. El modelo parece identificar mejor los rasgos distintivos del Topi (cuernos curvados y manchas oscuras en las

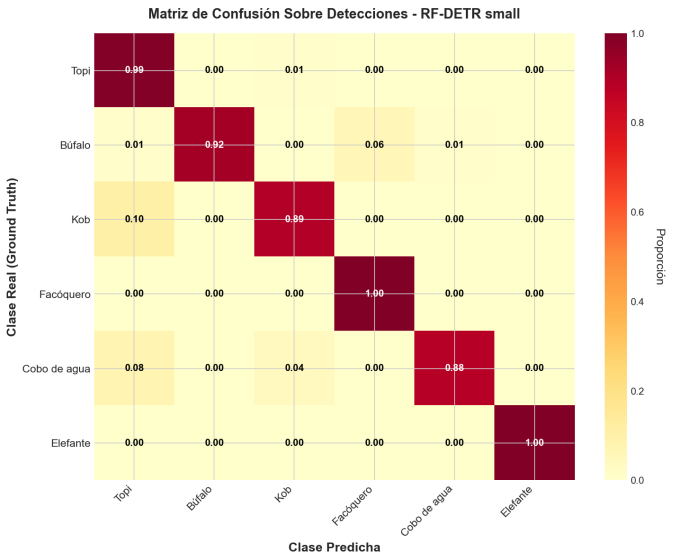


Figura 8. Matriz de confusión sobre las detecciones para RF-DETR small (Fase 2).

patas) que la morfología más genérica del Kob en ciertas posturas.

- **Cobo de agua → Antílopes (12 %):** Esta especie presenta confusiones divididas: un 8 % es clasificado erróneamente como Topi y un 4 % como Kob. Estas confusiones ocurren típicamente cuando el animal está parcialmente ocluido o en ángulos cenitales estrictos donde sus cuernos característicos en forma de lira no son visibles, llevando al modelo a asignarlo a las clases de antílopes mayoritarias.
- **Búfalo → Facóquero (6 %):** Se observa una confusión del 6 % de Búfalos clasificados como Facóqueros. Este error, aunque contraintuitivo por la diferencia de tamaño real, puede explicarse por la similitud en la coloración oscura y la textura de la piel en individuos juveniles o en tomas donde la escala relativa es ambigua debido a la altitud de vuelo.

IV-E1. Interpretación de la Clasificación Perfecta: Es notable que especies como el **Facóquero** y el **Elefante** alcancen un 100 % en la diagonal de la matriz. Sin embargo, este resultado debe interpretarse con rigor técnico:

- **Pureza vs. Exhaustividad:** El 100 % en la matriz indica una **precisión de clasificación condicional** perfecta: de todos los Facóqueros que el modelo logró detectar, ninguno fue confundido con otra especie.
- **Discrepancia con el Recall:** Este valor no contradice el bajo *Recall* de detección reportado anteriormente para el Facóquero (33.78 %). Significa que el modelo omite muchos individuos (falsos negativos de localización), pero cuando detecta uno, su clasificación semántica es impecable. Esto valida la efectividad del *HNP* para limpiar la frontera de decisión entre la clase Facóquero y el fondo, aunque la arquitectura aún lucha por recuperar instancias difíciles.

En conclusión, las confusiones se concentran en el clúster de antílopes (Kob-Topi-Cobo), mientras que las especies con morfologías más distintivas (Elefante, Facóquero, Búfalo) presentan una separabilidad semántica robusta.

IV-F. Evaluación Cualitativa en Especies Minoritarias

Se realizó una evaluación cualitativa enfocada en especies minoritarias bajo condiciones críticas de detección. Las Figuras 9 y 10 comparan las predicciones de los modelos contra Ground Truth en dos escenarios representativos.

IV-F1. Caso 1: Oclusión Severa en Elefantes: La Figura 9 ilustra cuatro elefantes parcialmente ocultos por vegetación densa. Los resultados de detección son:

- **HerdNet:** 2/4 detecciones (50 %). Falla en individuos con características distintivas ocultas (trompa, orejas), reflejando limitaciones del backbone ResNet-50 para capturar contexto global.
- **RF-DETR small y large:** 3/4 detecciones (75 %). Mejora del +50 % sobre HerdNet, detectando exitosamente individuos con hasta 50 % de oclusión.

Hallazgo clave: La oclusión representa un límite fundamental para todos los modelos, incluyendo arquitecturas Transformer. Aunque RF-DETR mejora significativamente sobre HerdNet, existe un umbral de oclusión que ningún modelo supera, y **RF-DETR nano** carece de la capacidad mínima necesaria para escenarios complejos.

IV-F2. Caso 2: Detección y Clasificación de Facóquero: La Figura 10 presenta dos facóqueros en terreno abierto , revelando un patrón diferente de error: confusión en clasificación pese a detección correcta.

- **HerdNet:** 2/2 detecciones pero 1/2 clasificación correcta (50 %). Detecta ambos individuos en las ubicaciones correctas pero clasifica uno erróneamente como Topi, evidenciando las limitaciones del backbone ResNet-50 para discriminar especies morfológicamente similares de tamaño medio.
- **RF-DETR small:** 2/2 detecciones y clasificación correcta (100 %). Lo que demuestra capacidad superior para discriminar Facóquero bajo condiciones de buena visibilidad, validando la efectividad del refinamiento mediante HNM y los mecanismos de atención.

Hallazgos clave: Este caso revela dos patrones críticos: (1) Con buena visibilidad, la detección espacial es exitosa incluso para HerdNet, pero la clasificación correcta requiere capacidades discriminativas superiores que solo los Transformers proveen. (2) Para especies minoritarias morfológicamente similares a especies mayoritarias (Facóquero vs Kob), los modelos CNN tienden a clasificar hacia la clase más frecuente, mientras que RF-DETR mantiene discriminación robusta. Esto valida la clasificación perfecta (100 %) de Facóquero reportada en la matriz de confusión para RF-DETR small.

V. Discusión

Los resultados validan la hipótesis de que la arquitectura RF-DETR supera al baseline HerdNet gracias a su diseño libre



Figura 9. Comparación cualitativa de detecciones en escenario con oclusión severa - Elefantes. Se observan 4 elefantes parcialmente ocultos por vegetación densa.



Figura 10. Comparación cualitativa de detecciones en especies minoritarias - Facóquero. Se muestran 2 individuos aislados en terreno de vegetación dispersa.

de NMS y al uso de representaciones visuales robustas. Sin embargo, el hallazgo más relevante de este estudio no es solo la mejora en precisión, sino la identificación de la arquitectura óptima en términos de costo-beneficio.

V-A. Small vs. Large: Eficiencia sobre Fuerza Bruta

Si bien se esperaba que la variante **Large** (aprox. 128M de parámetros) dominara las métricas debido a su mayor capacidad, los resultados muestran que la variante **Small** (aprox. 32M de parámetros) logró un rendimiento ligeramente superior en el F1-Score global (90.24 % vs 88.66 %).

Este fenómeno sugiere que el rendimiento del modelo ha alcanzado un punto de saturación respecto a la complejidad de la arquitectura para este dataset específico. Es probable que el modelo Large haya incurrido en un leve sobreajuste (*overfitting*), aprendiendo detalles irrelevantes del fondo en el conjunto de entrenamiento que penalizaron su generalización en la prueba.

Por lo tanto, la principal ventaja que ofrece el modelo small radica en que logró superar al modelo más potente utilizando una fracción de los parámetros y con un tiempo de inferencia un **56 % menor** (193 ms vs 442 ms). Esto lo convierte indiscutiblemente en la mejor opción para despliegue.

V-B. Análisis de Latencia: Eficiencia Estructural vs. Costo Computacional

El análisis de los tiempos de inferencia revela un comportamiento no lineal interesante entre las variantes **Nano** y **Small**, evidenciando un compromiso (*trade-off*) entre la eficiencia del preprocesamiento y el costo computacional bruto.

V-B1. Velocidad Promedio: La ventaja del modelo Small: En términos de latencia media, **RF-DETR Small** (193.39 ms) supera a la variante **Nano** (208.53 ms). Esto confirma la hipótesis de la *Ineficiencia del Teselado*: al utilizar una resolución de entrada mayor (512×512), el modelo Small requiere generar y ensamblar un número significativamente menor de parches para cubrir la misma área geográfica. La reducción en la sobrecarga administrativa (I/O, pre-procesamiento y fusión de resultados) compensa con creces el costo extra de inferencia por parche.

V-B2. Latencia de Cola (P95): La estabilidad del modelo Nano: Sin embargo, en el percentil 95 (P95), la tendencia se invierte: el modelo **Nano** muestra una latencia máxima menor (317.55 ms) comparada con el **Small** (352.77 ms). Esto se debe a la física fundamental del cálculo de tensores:

- Un parche del modelo Small (512^2 px) contiene un **77 % más de píxeles** que uno del modelo Nano (384^2 px).
- En escenarios de alta carga o complejidad visual extrema, el costo cuadrático de los mecanismos de atención del Transformer sobre mapas de características más grandes penaliza al modelo Small.

V-C. Small vs. Large: Eficiencia sobre Fuerza Bruta

Si bien se esperaba que la variante **Large** (aprox. 128M de parámetros) dominara las métricas debido a su mayor capacidad, los resultados muestran que la variante **Small** (aprox. 32M de parámetros) logró un rendimiento ligeramente superior en el F1-Score global (90.24 % vs 88.66 %).

Este fenómeno sugiere que el rendimiento del modelo ha alcanzado un punto de saturación respecto a la complejidad

de la arquitectura para este dataset específico. Es probable que el modelo Large haya incurrido en un leve sobreajuste (*overfitting*), aprendiendo detalles irrelevantes del fondo en el conjunto de entrenamiento que penalizaron su generalización en la prueba.

Por lo tanto, la principal ventaja que ofrece el modelo small radica en que logró superar al modelo más potente utilizando una fracción de los parámetros y con un tiempo de inferencia un **56 % menor** (193 ms vs 442 ms). Esto lo convierte indiscutiblemente en la mejor opción para despliegue.

V-D. Análisis de Latencia: Eficiencia Estructural vs. Costo Computacional

El análisis de los tiempos de inferencia revela un comportamiento no lineal interesante entre las variantes **Nano** y **Small**, evidenciando un compromiso (*trade-off*) entre la eficiencia del preprocesamiento y el costo computacional bruto.

V-D1. Velocidad Promedio: La ventaja del modelo Small: En términos de latencia media, **RF-DETR Small** (193.39 ms) supera a la variante **Nano** (208.53 ms). Esto confirma la hipótesis de la *Ineficiencia del Teselado*: al utilizar una resolución de entrada mayor (512×512), el modelo Small requiere generar y ensamblar un número significativamente menor de parches para cubrir la misma área geográfica. La reducción en la sobrecarga administrativa (I/O, pre-procesamiento y fusión de resultados) compensa con creces el costo extra de inferencia por parche.

V-D2. Latencia de Cola (P95): La estabilidad del modelo Nano: Sin embargo, en el percentil 95 (P95), la tendencia se invierte: el modelo **Nano** muestra una latencia máxima menor (317.55 ms) comparada con el **Small** (352.77 ms). Esto se debe a la física fundamental del cálculo de tensores:

- Un parche del modelo Small (512^2 px) contiene un **77 % más de píxeles** que uno del modelo Nano (384^2 px).
- En escenarios de alta carga o complejidad visual extrema, el costo cuadrático de los mecanismos de atención del Transformer sobre mapas de características más grandes penaliza al modelo Small.

Aunque las variantes **Nano** y **Small** presentan perfiles de latencia y tamaño comparables, la variante **Small** se consolida como la elección definitiva por su superioridad cualitativa. El incremento marginal en la resolución de entrada (512×512) permite superar el umbral mínimo de representación necesario para distinguir especies críticas (como el Elefante), logrando un salto en F1-Score del 71.78 % al 90.24 % sin incurrir en los costos de la variante Large.

V-E. Impacto del Hard Negative Mining (HNM)

El refinamiento con HNM fue el factor determinante para la viabilidad del modelo Small. Inicialmente, este modelo presentaba una precisión baja (0.26), indicando una tendencia a alucinar animales en texturas complejas. La fase 2 corrigió drásticamente este comportamiento (precisión 0.94), demostrando que los Transformers de tamaño medio tienen la plasticidad necesaria para aprender a discriminar fondos difíciles sin necesitar la capacidad masiva (y el costo) de los modelos Large.

V-F. Análisis por Especie

La mejora en la detección de especies minoritarias valida el uso de *backbones* pre-entrenados como DINOv2. En el caso del *Cobo de agua* (2.4 % del dataset), las variantes de RF-DETR mantuvieron un F1-Score robusto (mayor a 0.70), superando al baseline HerdNet. Esto indica que el modelo no requiere miles de ejemplos para aprender una representación discriminativa de una especie, un rasgo crucial para la conservación de fauna amenazada donde los datos son escasos por naturaleza.

V-G. Limitaciones y Oportunidades de Mejora

A pesar del éxito general del modelo **RF-DETR Small**, el análisis detallado de los resultados revela dos limitaciones técnicas importantes que definen el alcance actual de la solución y las direcciones futuras.

V-G1. El Límite Inferior de la Arquitectura Nano: La variante **Nano** mostró un rendimiento insuficiente (F1 global 71.78 %), colapsando dramáticamente en la clase *Elefante* con un F1-Score de apenas 0.0363, en marcado contraste con el $> 0{,}86$ logrado por las variantes Small y Large. Este fallo catastrófico establece un límite inferior claro: para distinguir patrones complejos en imágenes aéreas de alta altitud, se requiere una resolución de entrada mínima (al menos 512×512) y una profundidad de red que la versión Nano no ofrece.

V-G2. Margen de Mejora en Clases Minoritarias: Aunque RF-DETR mejoró la detección de especies subrepresentadas respecto a HerdNet, el desempeño en clases como el *Facóquero* (F1 0.4065 en Small) y el *Cobo de agua* (F1 0.7097 en Small) sigue siendo inferior al de las clases mayoritarias ($> 0{,}84$).

Es crucial notar que, a diferencia de HerdNet, el entrenamiento de RF-DETR **no implementó una ponderación agresiva de la función de pérdida** (HerdNet utilizó pesos de hasta 12 para clases minoritarias). Esto sugiere que el rendimiento actual de RF-DETR tiene un potencial significativo para aumentar aún más la precisión en estas clases críticas mediante la incorporación de estrategias de *Weighted Loss* o técnicas de sobre-muestreo (*Oversampling*) específicas para las especies menos representadas.

VI. Conclusiones y trabajo futuro

Esta investigación ha demostrado que las arquitecturas de detección de objetos basadas en Transformers, específicamente RF-DETR, representan una solución superior para la monitorización automatizada de fauna en manadas densas, superando las limitaciones inherentes a los métodos tradicionales basados en CNN y NMS. Los hallazgos clave se resumen a continuación:

- **Superioridad de la Arquitectura sin NMS:** La predicción directa de conjuntos (*end-to-end*) de RF-DETR resolvió eficazmente el problema de subconteo por oclusión. El modelo óptimo, **RF-DETR Small**, alcanzó un

F1-Score global de 90.24 %, superando al baseline HerdNet (83.26 %) y reduciendo el Error Medio Absoluto (MAE) de conteo en un **39.47 %**.

- **Eficiencia Óptima del Modelo Small:** Se identificó un punto de saturación en el rendimiento donde aumentar la complejidad del modelo no se traduce en ganancias significativas. La variante **Small** (32M parámetros) superó ligeramente a la variante **Large** (128M parámetros) en precisión global, siendo **56 % más rápida** en inferencia media (193 ms vs 442 ms), consolidándose como la opción ideal para el despliegue.
- **Validación del Hard Negative Mining:** El entrenamiento en dos fases fue crítico. La minería de negativos difíciles (HNM) transformó a RF-DETR Small de un modelo con precisión inaceptable (26.15 %) a la solución más precisa (93.85 %), demostrando la plasticidad del modelo para discriminar fondos complejos sin aumentar su tamaño.
- **Mejora en Especies Minoritarias:** El uso de *backbones* visuales robustos (DINOv2) mejoró significativamente la detección de clases subrepresentadas. En el caso crítico del Cobo de agua (2.4 % del dataset), RF-DETR Small mantuvo un F1-Score robusto superior al 70 %, validando su capacidad de generalización con pocos datos.
- **Limitación de la Resolución Mínima:** La variante Nano demostró ser insuficiente para esta tarea, colapsando en la detección de especies clave como el Elefante, lo que establece una resolución de entrada mínima de 512×512 como requisito para capturar patrones complejos en imágenes aéreas.

Para el trabajo futuro, se proponen dos direcciones principales:

a) **Mitigación Avanzada del Desbalance de Clases:** Aunque RF-DETR mejoró la detección base, persiste un margen de mejora en las clases minoritarias. Se propone incorporar estrategias de ponderación de pérdida (*Weighted Loss*) en la función de costo, replicando la estrategia de asignación agresiva de pesos que demostró ser efectiva en el entrenamiento de HerdNet. Alternativamente, se sugiere explorar técnicas de sobre-muestreo (*Oversampling*) para equilibrar la exposición del modelo a estas especies durante el entrenamiento.

b) **Optimización de Inferencia mediante cuantización:** Para facilitar el despliegue en dispositivos de borde, es necesario explorar la cuantización del modelo a INT8. Dado que las arquitecturas basadas en Transformers pueden sufrir degradación de rendimiento con una cuantización ingenua [5], se recomienda implementar esquemas de *Post-Training Quantization* (PTQ) calibrados [7] o *Quantization-Aware Training* (QAT). El objetivo es reducir la huella de memoria sin que la pérdida de precisión numérica afecte desproporcionadamente la localización en manadas densas [8].

c) **Entrenamiento con DINOV3 como extractor de características:** Si bien la implementación actual de RF-DETR utiliza DINOv2 [6], la evolución reciente de la arquitectura sugiere la adopción de DINOv3 [11]. Se recomienda evaluar la migración hacia este nuevo backbone, dado que ha demostrado superar a su predecesor en tareas de detección, logrando un rendimiento superior con una menor cantidad de parámetros y mayor eficiencia computacional [12]

REFERENCIAS

[1] Xu, Z., Wang, T., Skidmore, A. K., Lamprey, R. (2024). A review of deep learning techniques for detecting animals in aerial and satellite images. International Journal of Applied Earth Observation and Geoinformation, 128, 103732. https://doi.org/10.1016/j.jag.2024.103732

[2] Delplanque, A., Foucher, S., Théau, J., Bussière, E., Vermeulen, C., Lejeune, P. (2023). From crowd to herd counting: How to precisely detect and count African mammals using aerial imagery and deep learning? ISPRS Journal of Photogrammetry and Remote Sensing, 197, 167–180. https://doi.org/10.1016/j.isprsjprs.2023.01.025

[3] Kumar, S., Zhang, B., Gudavalli, C., Levenson, C., Hughey, L., Stabach, J. A., Amoke, I., Ojwang, G., Mukeka, J., Mwiu, S., Ogutu, J., Frederick, H., Manjunath, B. S. (2024). WildlifeMapper: Aerial image analysis for multi-species detection and identification. En 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 12594–12604). IEEE. https://doi.org/10.1109/CVPR52733.2024.01197

[4] Patel, M., Noa Turnes, J., Hsiao, J., Xu, L., Clausi, D. (2025). OpenWildlife: Open-vocabulary multi-species wildlife detector for geographically-diverse aerial imagery. arXiv. https://doi.org/10.48550/arXiv.2506.19204

[5] Robinson, I., Robicheaux, P., Popov, M., Ramanan, D., Peri, N. (2025). RF-DETR: Neural Architecture Search for Real-Time Detection Transformers. arXiv. https://doi.org/10.48550/arXiv.2511.09554

[6] Oquab, M., Darcet, T., Moutakanni, T., Vo, H. V., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., ... Synnaeve, G. (2024). DINOv2: Learning robust visual features without supervision. Transactions on Machine Learning Research.

[7] Wu, Z., Wang, S., Zhang, J., Chen, J., Wang, Y. (2025). FIMA-Q: Post-training quantization for vision transformers by Fisher information matrix approximation. arXiv. https://doi.org/10.48550/arXiv.2506.11543

[8] Huang, L., Dong, Z., Chen, S.-L., Zhang, R., Ti, S., Chen, F., Yin, X.-C. (2024). HQOD: Harmonious quantization for object detection. En 2024 IEEE International Conference on Multimedia and Expo (ICME) (pp. 1–6). IEEE. https://doi.org/10.1109/ICME57554.2024.10687589

[9] Huang, S., Hou, Y., Liu, L., Yu, X., Shen, X. (2025). Real-Time Object Detection Meets DINOv3. arXiv preprint arXiv:2509.20787. https://arxiv.org/abs/2509.20787

[10] Delplanque, A., Foucher, S., Lejeune, P., Linchant, J., Théau, J. (2021). Multispecies detection and identification of African mammals in aerial imagery using convolutional neural networks. Remote Sensing in Ecology and Conservation, 8(2), 166–179. https://doi.org/10.1002/rse2.234

[11] Siméoni, O., Vo, H. V., Seitzer, M., Baldassarre, F., Oquab, M., Jose, C., Khalidov, V., Szafraniec, M., Yi, S., Ramamonjisoa, M., Massa, F., Haziza, D., Wehrstedt, L., Wang, J., Darcet, T., Moutakanni, T., Sentana, L., Roberts, C., Vedaldi, A., Tolan, J., Brandt, J., Couprie, C., Mairal, J., Jégou, H., Bojanowski, P. (2025). DINOv3. arXiv preprint arXiv:2508.10104. https://arxiv.org/abs/2508.10104

[12] Huang, S., Hou, Y., Liu, L., Yu, X., Shen, X. (2025). Real-Time Object Detection Meets DINOv3. arXiv preprint arXiv:2509.20787. https://arxiv.org/abs/2509.20787

ANEXOS

Anexo A. Repositorio de Código y Reproducibilidad

Para garantizar la transparencia y replicabilidad de los experimentos, el código fuente completo, los pipelines de procesamiento y los scripts de entrenamiento se encuentran disponibles públicamente en:

`https://github.com/amir1226/animaldet`

El entorno de desarrollo utiliza el gestor de paquetes `uv` para manejar dependencias en conflicto mediante grupos aislados (`herdnet` y `rfdetr`), asegurando que cada arquitectura se ejecute con las versiones de bibliotecas exactas utilizadas durante la investigación.

Anexo B. Hiperparámetros y Configuración del Entrenamiento

Este anexo documenta los hiperparámetros y configuraciones utilizados durante el entrenamiento de los modelos HerdNet y RF-DETR (Nano, Small, Large). Todos los entrenamientos se ejecutaron en GPU NVIDIA A100 (80GB VRAM) utilizando PyTorch 2.x y CUDA 12.x.

B.1 HerdNet (Baseline):

VI-0a. Fase 1 - Entrenamiento Inicial:

- **Épocas:** 100
- **Learning Rate Inicial:** 1×10^{-4}
- **Optimizador:** Adam
- **Weight Decay:** 5×10^{-4}
- **Batch Size:** 4
- **Learning Rate Schedule:** ReduceLROnPlateau
  - Mode: max (monitorea F1-Score)
  - Patience: 10 épocas
  - Threshold: 1×10^{-4}
  - Cooldown: 10 épocas
  - Min LR: 1×10^{-6}
- **Tamaño de parche:** 512×512 píxeles
- **Down Ratio:** 2 (para localización)
- **Warmup Iterations:** 100

VI-0b. Funciones de Pérdida (Fase 1):

- **Localización:** Focal Loss (reduction='mean', normalize=False)
- **Clasificación:** Weighted Cross-Entropy Loss
- **Pesos por clase:** $w = [0{,}1, 1{,}0, 2{,}0, 1{,}0, 6{,}0, 12{,}0, 1{,}0]$

VI-0c. Fase 2 - Hard Negative Mining:

- **Épocas:** 50
- **Learning Rate Inicial:** 1×10^{-6} (reducido 100×)
- **Optimizador:** Adam
- **Weight Decay:** 5×10^{-4}
- **Batch Size:** 4
- **Warmup Iterations:** 1
- **Validation Frequency:** Cada 10 épocas
- **Pesos por clase:** Idénticos a Fase 1
- **Checkpoint Inicial:** Mejor modelo de Fase 1 (selección por F1-Score máximo)

B.2 RF-DETR (Todas las variantes): La Tabla III resume los hiperparámetros para las tres variantes de RF-DETR. Se destacan las diferencias en la resolución de entrada y la cantidad de parámetros.

Tabla III
HIPERPARÁMETROS DE ENTRENAMIENTO PARA RF-DETR (NANO, SMALL, LARGE).

Parámetro	**Nano**	**Small**	**Large**
Arquitectura			
Tamaño de Entrada	384×384	512×512	560×560
Backbone Base	DINOv2	DINOv2	DINOv2
Parámetros (aprox.)	**30.5 M**	**32.1 M**	**128 M**
Fase 1 - Entrenamiento Inicial			
Épocas	50	50	50
Batch Size	16	16	16
Grad Accum Steps	4	4	4
Batch Efectivo	**64**	**64**	**64**
Learning Rate	Default*	Default*	Default*
Optimizador	AdamW	AdamW	AdamW
Fase 2 - Hard Negative Mining			
Épocas	50	50	50
Batch Size	2	2	2
Grad Accum Steps	8	8	8
Batch Efectivo	**16**	**16**	**16**
Learning Rate (Decoder)	1×10^{-5}	1×10^{-5}	1×10^{-5}
Learning Rate (Encoder)	1×10^{-5}	1×10^{-5}	1×10^{-5}
Weight Decay	1×10^{-4}	1×10^{-4}	1×10^{-4}
EMA Decay	0.993	0.993	0.993
Multi-Scale Training	✓	✓	✓

**Default: Learning rate con decaimiento por capas (layer-wise decay) según configuración estándar del framework RF-DETR* 1×10^{-4}.

Anexo C. Métricas Detalladas por Especie

Este anexo presenta una desagregación completa de las métricas de rendimiento por especie para los cuatro modelos evaluados (HerdNet, RF-DETR Nano, RF-DETR Small, RF-DETR Large) en la Fase 2 del entrenamiento (con HNM). Las tablas permiten analizar el desempeño específico de cada arquitectura en el manejo de especies minoritarias y mayoritarias.

C.1 Topi: El Topi representa una de las especies mayoritarias del dataset (2.722 individuos, 26.6 % del total). La Tabla IV muestra que todos los modelos alcanzan un rendimiento elevado en esta especie, con F1-Scores superiores al 83 %.

Tabla IV
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE TOPI (FASE 2).

Métrica	**HerdNet**	**RF-DETR Nano**	**RF-DETR Small**	**RF-DETR Large**
F1-Score	0.8559	0.8381	**0.8960**	0.8550
Precision	0.8371	0.7615	**0.8800**	0.7909
Recall	0.8756	0.9319	0.9126	**0.9304**
MAE	1.7042	2.1059	**1.5735**	1.9615
RMSE	2.8009	3.4007	**2.9180**	3.3722

C.2 Búfalo: El Búfalo es otra especie mayoritaria del dataset (1.509 individuos, 14.7 % del total). La Tabla V revela un patrón de rendimiento similar al Topi, con mejoras consistentes de RF-DETR Small.

Tabla V
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE BÚFALO (FASE 2).

Métrica	HerdNet	RF-DETR Nano	RF-DETR Small	RF-DETR Large
F1-Score	0.8115	0.8024	**0.8435**	0.8313
Precision	0.9170	0.8471	**0.9531**	0.8944
Recall	0.7278	0.7622	0.7564	**0.7765**
MAE	3.5000	3.1786	3.3333	**3.0400**
RMSE	5.9702	6.2593	6.4936	**5.9464**

C.3 Kob: El Kob es una especie mayoritaria del dataset (2.370 individuos, 23.1 % del total). La Tabla VI muestra un rendimiento excepcional de RF-DETR Small.

Tabla VI
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE KOB (FASE 2).

Métrica	HerdNet	RF-DETR Nano	RF-DETR Small	RF-DETR Large
F1-Score	0.8751	0.8156	**0.9051**	0.8019
Precision	0.8484	0.7812	**0.9432**	0.9029
Recall	**0.9036**	0.8532	0.8700	0.7212
MAE	1.0283	1.2952	**0.6915**	1.5506
RMSE	1.9882	2.1647	**1.8072**	3.2568

C.4 Facóquero: El Facóquero es una especie minoritaria del dataset (433 individuos, 4.2 % del total). La Tabla VII revela uno de los desafíos más significativos del estudio: todos los modelos presentan un rendimiento limitado en esta clase.

Tabla VII
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE FACÓQUERO (FASE 2).

Métrica	HerdNet	RF-DETR Nano	RF-DETR Small	RF-DETR Large
F1-Score	0.4151	0.3788	0.4065	**0.4493**
Precision	0.3882	0.4310	0.5102	**0.4844**
Recall	**0.4459**	**0.3378**	**0.3378**	**0.4189**
MAE	2.2432	2.4667	2.4815	**2.4000**
RMSE	**3.1322**	3.5496	3.5013	3.4351

C.5 Cobo de agua: El Cobo de agua es la especie más minoritaria del dataset (241 individuos, 2.4 % del total). La Tabla VIII muestra el impacto más pronunciado de las arquitecturas basadas en Transformers.

Tabla VIII
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE COBO DE AGUA (FASE 2).

Métrica	HerdNet	RF-DETR Nano	RF-DETR Small	RF-DETR Large
F1-Score	0.6849	0.6237	0.7097	**0.8158**
Precision	0.6757	0.5088	0.8462	**0.7750**
Recall	0.6944	**0.8056**	0.6111	**0.8611**
MAE	1.2500	1.4375	2.5714	**1.2000**
RMSE	1.5000	2.2500	3.0237	**1.4142**

C.6 Elefante: El Elefante es la especie más numerosa del dataset (2.964 individuos, 28.9 % del total). La Tabla IX revela el fallo de RF-DETR Nano en esta clase.

Tabla IX
MÉTRICAS DE RENDIMIENTO PARA LA ESPECIE ELEFANTE (FASE 2).

Métrica	HerdNet	RF-DETR Nano	RF-DETR Small	RF-DETR Large
F1-Score	0.6956	0.0363	0.8649	**0.8641**
Precision	0.6707	0.4483	0.8995	**0.8549**
Recall	0.7224	0.0189	0.8328	**0.8735**
MAE	2.5728	6.5900	**1.0700**	1.2300
RMSE	4.4142	10.3068	**1.5969**	3.9154

Anexo D. Ejemplos Cualitativos Adicionales

A continuación, la Figura 11 ilustra los resultados de detección para el Cobo de agua. Esta comparación cualitativa sobre 4 individuos permite visualizar el desempeño de los modelos en una de las especies con menor representación (minoritaria) en el conjunto de entrenamiento.

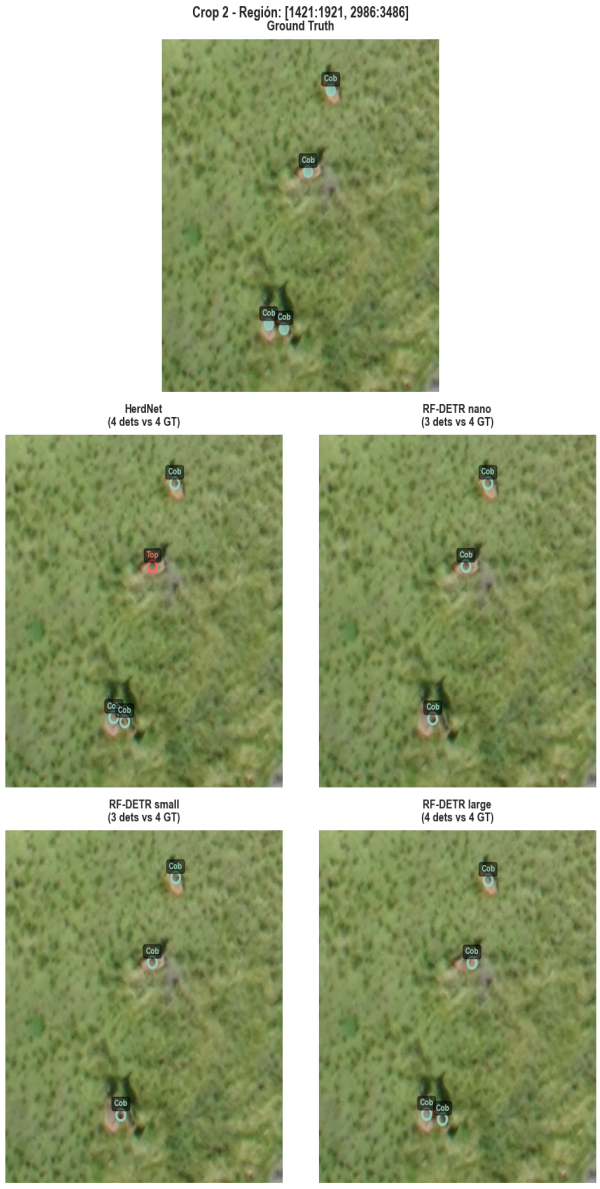


Figura 11. Comparación cualitativa del cobo de agua. Se observan 4 cobos de agua.

La Figura 12 presenta un escenario con 2 individuos de la especie Topi. Esta comparación sirve para evaluar la precisión de clasificación y localización en una de las especies de antílopes más frecuentes y de tamaño medio del conjunto de datos.

En la siguiente Figura 13 se visualizan los resultados para el Facóquero. Este ejemplo con 3 individuos es crítico para analizar la capacidad de los diferentes modelos para detectar objetivos de tamaño muy pequeño, un desafío donde suelen ocurrir omisiones (falsos negativos).

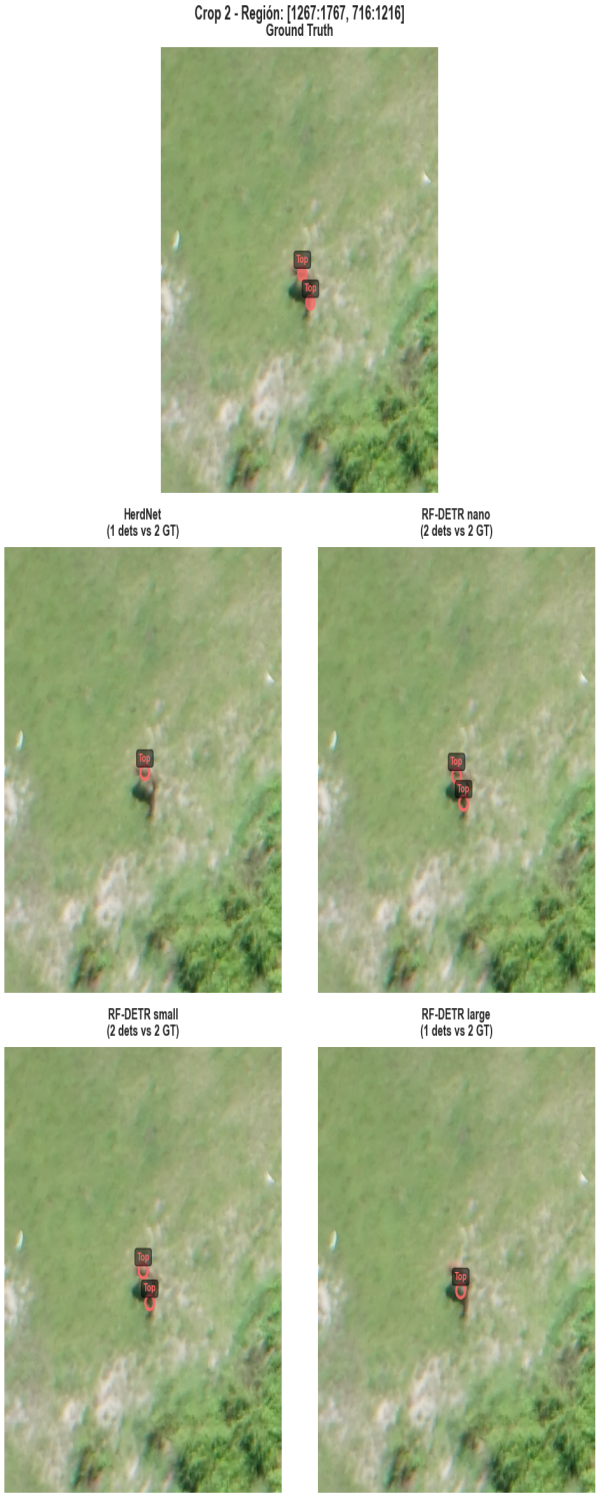


Figura 12. Comparación cualitativa del topi. Se observan 2 topis.



Figura 13. Comparación cualitativa del Facóquero. Se observan 2 facóqueros.

Por último, la Figura 14 presenta una comparación cualitativa sobre un grupo de 6 Búfalos. Este escenario permite observar el comportamiento de los detectores ante una especie de gran tamaño, coloración oscura y morfología distintiva.

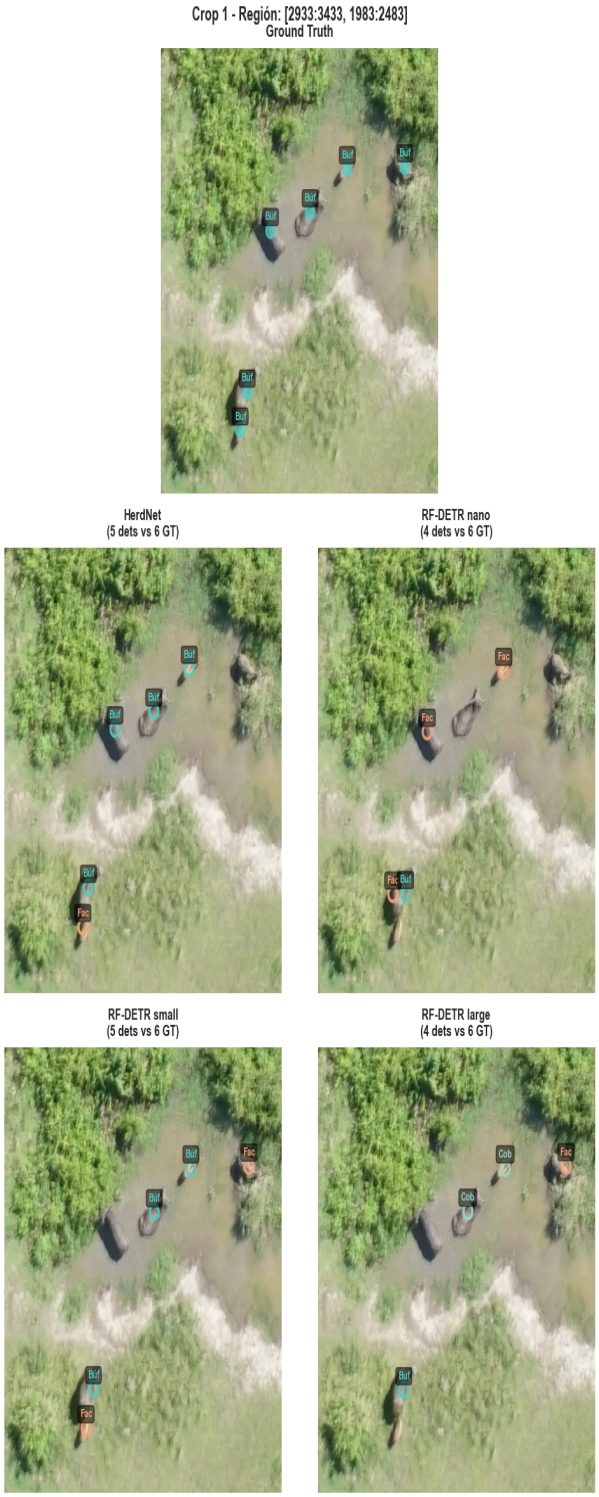


Figura 14. Comparación cualitativa del Búfalo. Se observan 6 búfalos.